

Trabajo Final Lenguajes

12/12/2025

Marino Agustin
Ricciardi Nicolás

1. Introducción

El análisis de datos permite extraer conocimiento a partir de grandes volúmenes de información y constituye una herramienta clave en múltiples áreas, incluida la industria cinematográfica. Mediante el estudio de variables económicas, artísticas y temporales, es posible identificar patrones de rentabilidad, tendencias de consumo y relaciones entre inversión y calidad percibida.

En este trabajo se realiza un análisis descriptivo sobre un conjunto de datos de películas provenientes de **The Movie Database (TMDB)**. El análisis se desarrolla en dos instancias complementarias: un **Notebook de Análisis Exploratorio de Datos (EDA)** y una **Mini-API local**, que expone los principales resultados en formato JSON.

2. Objetivos

Objetivo general

Analizar descriptivamente un conjunto de datos cinematográficos y exponer los resultados mediante herramientas de análisis y desarrollo de software.

Objetivos específicos

- Explorar y describir las principales características del dataset.
 - Limpiar y preparar los datos para su análisis.
 - Analizar la rentabilidad (ROI) de las películas por género.
 - Estudiar la relación entre presupuesto y rating.
 - Analizar la evolución temporal de la duración de las películas.
 - Generar archivos resumidos para su reutilización en una mini API local.
 - Implementar una API que devuelva los principales resultados del análisis.
-

3. Metodología

3.1. Fuentes de datos

Se utilizaron datasets públicos de TMDB obtenidos desde Kaggle:

- `tmdb_5000_movies.csv`
- `tmdb_5000_credits.csv`

Los datos incluyen información de aproximadamente 4800 películas, tales como presupuesto, recaudación, géneros, duración, fechas de estreno, ratings y equipos de producción.

3.2. Herramientas utilizadas

- **Python**
 - **Pandas y NumPy** para análisis y procesamiento
 - **Matplotlib y Seaborn** para visualización
 - **Jupyter Notebook** para el EDA
 - **FastAPI** para la implementación de la API local
-

4. Notebook de Análisis Exploratorio de Datos (EDA)

Como parte central del trabajo, se desarrolló un **Notebook (.ipynb)** que documenta de manera ordenada todo el proceso de análisis exploratorio, limpieza y generación de resultados.

Este notebook funciona como base analítica del proyecto y como fuente de datos para la mini API.

4.1. Lectura y descripción del dataset

En la primera sección del notebook se realizó la lectura de los datasets mediante `pandas`. Se analizaron las dimensiones, tipos de datos y valores nulos utilizando los métodos `info()`, `describe()` y `head()`.

Este análisis inicial permitió identificar:

- Alta dispersión en variables económicas (`budget`, `revenue`).
 - Columnas complejas almacenadas como strings en formato JSON.
 - Presencia de valores faltantes o inválidos.
-

4.2. Limpieza y preparación de los datos

Durante esta etapa se realizaron las siguientes tareas:

- Conversión de la columna `release_date` a formato fecha.
- Extracción del año de estreno y creación de variables temporales.
- Transformación de columnas en formato JSON a listas y diccionarios reales.
- Exclusión de registros con presupuestos iguales a cero para evitar errores en el cálculo del ROI.
- Creación de variables derivadas como:
 - **ROI (Return on Investment)** = $\text{revenue} / \text{budget}$
 - **Década de estreno**

Este proceso permitió obtener un dataset consistente y apto para el análisis estadístico.

4.3. Análisis exploratorio (EDA)

El análisis exploratorio incluyó estadísticas descriptivas y visualizaciones gráficas. Entre los principales análisis realizados se destacan:

- Distribución y comparación del ROI por género cinematográfico.
- Gráficos de dispersión para analizar la relación entre presupuesto y rating.
- Análisis temporal de la duración de las películas agrupadas por década.

Cada sección del notebook contiene **comentarios explicativos y conclusiones parciales**, facilitando la interpretación de los resultados.

4.4. Respuestas a las preguntas de análisis

El notebook responde explícitamente a los ejes de análisis planteados en el trabajo práctico:

- **Rentabilidad por género:** se identificaron géneros con alta eficiencia económica.
- **Presupuesto vs rating:** se comprobó que no existe una relación lineal fuerte entre inversión y valoración del público.
- **Evolución temporal:** se observó un leve aumento en la duración de las películas en las últimas décadas.

Estas respuestas se fundamentan en estadísticas y gráficos obtenidos durante el EDA.

4.5. Generación de archivos para la API

Como cierre del notebook, se generaron archivos resumidos en formatos `.csv` y `.json`, tales como:

- Rentabilidad promedio por género.
- Evolución de la duración de las películas por década.

Estos archivos son utilizados directamente por la mini API, asegurando coherencia entre el análisis y los servicios expuestos.

5. Mini-API local

Como cierre integrador del trabajo, se desarrolló una **mini API local utilizando FastAPI**, que permite acceder a los principales resultados del análisis en formato JSON.

5.1. Objetivo de la API

El objetivo de la API es exponer los resultados del análisis de manera estructurada, reutilizable y fácilmente accesible, sin necesidad de desplegar el servicio en línea.

5.2. Endpoints implementados

Entre los endpoints desarrollados se incluyen:

- `/roi_por_genero`
Devuelve los géneros con mayor rentabilidad promedio.
 - `/roi_por_pais`
Devuelve países con mayor rentabilidad mediana, considerando un mínimo de películas.
 - `/top_directores`
Devuelve directores con mejor rating promedio (según cantidad mínima de películas).
 - `/correlacion_presupuesto_rating`
Devuelve los coeficientes de correlación entre presupuesto y rating.
-

5.3. Ejecución local

Explicado en el README del GitHub

6. Conclusiones

A partir del análisis realizado se concluye que:

- La rentabilidad de una película varía significativamente según el género.
- Un mayor presupuesto no garantiza una mejor valoración por parte del público.
- La duración de las películas ha aumentado moderadamente en las últimas décadas.
- El uso de notebooks facilita el análisis reproducible y documentado.
- La mini API permite reutilizar y exponer los resultados de forma clara y estructurada.

El trabajo integra exitosamente análisis de datos y desarrollo de software, demostrando una aplicación práctica de los conceptos aprendidos.

7. Bibliografía y fuentes

- Kaggle – TMDb 5000 Movie Dataset
<https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata>
- Documentación oficial de Pandas
<https://pandas.pydata.org/docs/>
- Documentación oficial de FastAPI
<https://fastapi.tiangolo.com/>